


# Healthcare Medical Project

## Informe Técnico — Reingreso Hospitalario a 30 Días

---



David Mourenza Fantáns · Enrique Jiménez Martínez · Gael Díaz López · Paula Domínguez Reig

*Máster FP Dual — Inteligencia Artificial y Big Data · Curso 2025-2026*  
NTT Data, A Coruña

|                                                                              |   |
|------------------------------------------------------------------------------|---|
| Índice .....                                                                 | 1 |
| 1. Origen del Dataset y Problema de Negocio .....                            | 2 |
| 2. Variables y Feature Engineering .....                                     | 3 |
| 2.1 Variables originales — top 6 por correlación Spearman con el target..... | 3 |
| 2.2 Variables derivadas — 22 features construidas .....                      | 3 |
| Temporales (4) .....                                                         | 3 |
| Umbrales clínicos binarios (5) .....                                         | 4 |
| Interacciones multiplicativas (8) .....                                      | 4 |
| Score compuesto y términos cuadráticos (4).....                              | 4 |
| 2.3 Selección final y decisiones metodológicas .....                         | 4 |
| 3. Modelos, Entrenamiento y Métricas .....                                   | 5 |
| 3.1 Configuración y balanceo de clases .....                                 | 5 |
| 3.2 Descripción y resultados por modelo .....                                | 5 |
| Modelo 1 — Logistic Regression (baseline lineal) .....                       | 5 |
| Modelo 2 — Random Forest .....                                               | 5 |
| Modelo 3 — HistGradientBoosting .....                                        | 5 |
| Modelo 4 — Red Neuronal MLP (descartado) .....                               | 5 |
| Modelo 5 — XGBoost.....                                                      | 5 |
| 3.3 Stacking — modelo final.....                                             | 5 |
| 3.4 Por qué el Stacking es el modelo final .....                             | 6 |
| Conclusión.....                                                              | 6 |

# 1. Origen del Dataset y Problema de Negocio

**Dataset:** [patient-records-100k-patients-15-conditions](#). 100.000 pacientes distribuidos en 5 CSV (patients, outcomes, medications, diagnoses, lab\_results), generados con distribuciones basadas en datos reales de Medicare (EE. UU.). Variable objetivo: readmitted\_30d — **9.358 negativos (85,1%) y 1.643 positivos (14,9%)**.

**Métrica principal — Recall y F2, no Accuracy:** Un modelo que prediga siempre "no reingresa" obtiene Accuracy=85,1% con Recall=0%. En contexto sanitario, un Falso Negativo (paciente de riesgo enviado a casa sin seguimiento) tiene un coste clínico muy superior a un Falso Positivo. Por eso se optimiza el Recall y se usa F2-score (Recall pesa 4× sobre Precisión) como métrica compuesta.

**Problema de negocio:** La solución aporta valor en tres niveles:

- **Atención al paciente:** Priorizar el seguimiento ambulatorio de pacientes de alto riesgo y ajustar el plan terapéutico antes del alta, reduciendo complicaciones evitables. El reingreso a 30 días es uno de los indicadores de calidad asistencial más utilizados por sistemas como Medicare o el NHS.
- **Gestión de recursos:** Planificar ocupación de camas, dimensionar turnos y asignar personal por servicio en función del volumen esperado de reingresos. Una alerta del tipo "se esperan 18 reingresos esta semana frente a la media de 12" permite activar recursos con días de margen.
- **Eficiencia operativa:** Reducir el coste por proceso: según el CMS, un reingreso no planificado supera los 15.000 \$. Reducir la tasa un 5% en un hospital de 500 camas representa un ahorro potencial de cientos de miles de euros anuales.

## 2. Variables y Feature Engineering

### 2.1 Variables originales — top 6 por correlación Spearman con el target

De los 5 CSV integrados se extrajeron 75 variables. Se eliminaron las que causan data leakage (días hasta reingreso, costes, fallecimiento en planta) y los identificadores. Solo 8 variables tienen  $|r|>0,05$  y 2 superan  $|r|>0,10$ . El máximo es  $|r|=0,125$ , lo que fija el techo teórico del AUC en  $\sim 0,65$ .

| Variable                  | r     | Interpretación clínica                                                        |
|---------------------------|-------|-------------------------------------------------------------------------------|
| charlson_index            | 0,125 | Índice de comorbilidad validado — predictor principal del riesgo de reingreso |
| dx_chronic_kidney_disease | 0,102 | ERC: una de las 5 causas con mayor tasa de reingreso a 30 días                |
| lab_creatinine            | 0,079 | Disfunción renal activa — creatinina $>1,2$ mg/dL indica deterioro agudo      |
| n_medications             | 0,073 | Polifarmacia: riesgo de interacciones y errores de medicación al alta         |
| n_unique_icd              | 0,070 | Diversidad diagnóstica: mayor complejidad del paciente                        |
| pct_abnormal              | 0,061 | % analíticas fuera de rango: inestabilidad clínica al momento del alta        |

### 2.2 Variables derivadas — 22 features construidas

Se construyeron 22 nuevas variables para capturar información que las originales no expresan directamente:

#### Temporales (4)

| Variable          | Justificación                                                                                                        |
|-------------------|----------------------------------------------------------------------------------------------------------------------|
| admission_month   | Reingresos más frecuentes en invierno (EPOC, ICC) y verano (deshidratación). Captura estacionalidad clínica.         |
| admission_weekday | Altas de viernes/fin de semana tienen menor acceso a seguimiento ambulatorio inmediato, aumentando el riesgo precoz. |
| admission_quarter | Estacionalidad agrupada (Q1=invierno, Q3=verano) cuando el mes individual tiene demasiada varianza.                  |

| Variable        | Justificación                                                                                            |
|-----------------|----------------------------------------------------------------------------------------------------------|
| n_comorbidities | Suma de todos los dx_* activos. La carga total de comorbididades es uno de los predictores más robustos. |

## Umrales clínicos binarios (5)

| Variable (umbral)               | Justificación del punto de corte                                                                                      |
|---------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| high_charlson (>=3)             | Umbral clínico validado: Charlson >=3 = mortalidad >50% a 1 año. Binarizar captura el efecto no lineal del umbral.    |
| high_creatinine (>1,2 mg/dL)    | Referencia clínica de disfunción renal incipiente.                                                                    |
| high_abnormal (>30% labs)       | Más del 30% de analíticas fuera de rango indica descompensación multiorgánica activa e inestabilidad clínica al alta. |
| high_meds (>P75)                | Polifarmacia por encima del P75 aumenta el riesgo de interacciones y errores de medicación.                           |
| high_emergency urgencias) (>=2) | Dos o más urgencias en el historial indica inestabilidad clínica basal recurrente.                                    |

## Interacciones multiplicativas (8)

| Variable              | Justificación clínica                                                                                |
|-----------------------|------------------------------------------------------------------------------------------------------|
| charlson_x_meds       | Carga crónica alta + polifarmacia: riesgo sinérgico compuesto mayor que la suma de ambos factores.   |
| charlson_x_comorbid   | Charlson (gravedad) x n_comorbidities (cantidad): pacientes con multi-morbilidad grave.              |
| charlson_x_emergency  | Severidad crónica x descompensaciones agudas frecuentes sobre fondo grave.                           |
| charlson_x_abnormal   | Paciente grave con labs muy alterados: doble señal de riesgo inmediato de reingreso.                 |
| creatinine_x_charlson | Síndrome cardiorrenal: ICC + disfunción renal, tasa de reingreso >40% a 30 días.                     |
| abnormal_x_meds       | Labs anormales en polimedcado: posible toxicidad farmacológica activa en curso.                      |
| delta_x_charlson      | Desviación máxima del rango normal x severidad crónica: inestabilidad aguda sobre fondo crónico.     |
| meds_x_adherence      | Muchos medicamentos + baja adherencia: mayor riesgo de descompensación que cada factor por separado. |

## Score compuesto y términos cuadráticos (4)

| Variable                                    | Justificación                                                                                                                                                         |
|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| clinical_risk_score                         | Ponderado según literatura: Charlson·0,40 + creatinina alta·0,25 + pct_abnormal·0,20 + ERC·0,15.                                                                      |
| charlson_sq / creatinine_sq / risk_score_sq | El riesgo crece de forma no lineal: Charlson=6 implica riesgo mucho mayor que 2×Charlson=3. Los términos cuadráticos modelan esta aceleración en el extremo superior. |

## 2.3 Selección final y decisiones metodológicas

- **Selección de features:** Etapa 1 — Filtro Spearman  $|r| \geq 0,03$  sobre train: 80 numéricas → 15 con señal mínima. Etapa 2 — SelectKBest k=15 (mutual\_info\_classif): 15 features finales para entrenamiento. 8.800 muestras train / 2.201 test.
- **PCA descartado:** PCA evaluado y descartado: para el 95% de varianza se necesitan 35 componentes. PCA maximiza varianza general, no correlación con el target. Con max  $|r|=0,125$  mezcla señal con ruido. SelectKBest selecciona directamente por relevancia.

- **SMOTE descartado:** Riesgo de contaminación de folds si se aplica antes del split (observado: CV-AUC=0,89 vs AUC test=0,56). Sin ventaja sobre `class_weight='balanced'` nativo. No requiere dependencias externas.

## 3. Modelos, Entrenamiento y Métricas

### 3.1 Configuración y balanceo de clases

GridSearchCV con StratifiedKFold 5 folds, `scoring=roc_auc` (umbral-independiente y estable para comparar hiperparámetros). Umbral de decisión final: maximiza F2 con Precisión  $\geq 25\%$  sobre train (garantía: por cada 4 alertas lanzadas, al menos 1 es un reingreso real). Balanceo: `class_weight='balanced'` para LR/RF/HGB, `scale_pos_weight=3,0` para XGBoost, `alpha=10,0` como compensación para MLP. SMOTE descartado (ver §2.3).

### 3.2 Descripción y resultados por modelo

#### Modelo 1 — Logistic Regression (baseline lineal)

**Qué es:** Modelo lineal que calcula una combinación ponderada de las 15 features y pasa el resultado por una función sigmoide para obtener probabilidades en  $[0,1]$ . El más interpretable: cada coeficiente indica cuánto contribuye cada feature al riesgo. **Parámetros óptimos:** `C=0,01` (L2 fuerte, previene sobreajuste con señal débil).

#### Modelo 2 — Random Forest

**Qué es:** Ensemble de 200 árboles entrenados en muestras aleatorias (bagging). `max_features=sqrt` añade aleatoriedad en los splits, reduciendo la correlación entre árboles. Robusto con features mixtas, no asume normalidad. **Parámetros óptimos:** `n_estimators=200`, `max_depth=4`, `min_samples_leaf=30`.

#### Modelo 3 — HistGradientBoosting

**Qué es:** Boosting secuencial basado en histogramas, inspirado en LightGBM. 50x más rápido que GBM clásico. Maneja NaN nativamente. **Parámetros óptimos:** `lr=0,05`, `max_depth=2`, `max_iter=50`, `min_samples_leaf=20`, `l2=10,0`, `early_stopping`.

#### Modelo 4 — Red Neuronal MLP

**Qué es:** Red de 2 capas (32→16 neuronas), ReLU en capas ocultas, sigmoide en salida. **Parámetros óptimos:** `alpha=10,0`, `arch=32→16`, 33 iteraciones (early stopping).

#### Modelo 5 — XGBoost

**Qué es:** Boosting con regularización L1 (`reg_alpha`, esparsidad) y L2 (`reg_lambda`, shrinkage) independientes. Submuestreo estocástico por árbol equivalente al dropout. **Parámetros óptimos:** `scale_pos_weight=3,0`, `max_depth=2`, `lr=0,01`, `n_est=100`, `min_child_weight=15`, `gamma=0,1`, `reg_lambda=10,0`, `subsample=0,75`.

### 3.3 Stacking — modelo final

**Qué es:** Combina las probabilidades de los 4 modelos base como inputs de un meta-modelo (LR, `C=0,1`, `class_weight='balanced'`). Usa out-of-fold (`cv=5`): los modelos base predicen sobre el fold que no vieron en entrenamiento, de forma que el meta-modelo aprende sobre predicciones honestas sin data leakage. `passthrough=False`: el meta-modelo solo ve las 4 probabilidades, no las 15 features originales.

**Por qué supera a los modelos base:** Cada modelo base comete errores distintos. LR falla en interacciones no lineales; RF sobreajusta en subgrupos; HGB y XGBoost tienen probabilidades comprimidas a umbrales altos. El meta-modelo aprende a compensar estas debilidades y produce probabilidades con distribución más amplia, permitiendo un umbral de 0,532 que satisface Precisión  $\geq 25\%$  con Recall=0,635 — imposible de alcanzar con cualquier modelo base por separado.

| Modelo     | Score  | AUC   | Recall | F2    | Accuracy | CV-AUC | $\Delta$ AUC | Tiempo |
|------------|--------|-------|--------|-------|----------|--------|--------------|--------|
| Stacking ★ | 0,6737 | 0,621 | 0,635  | 0,431 | 53,7%    | 0,6010 | +0,001       | 2,6 s  |

| Modelo               | Score  | AUC   | Recall | F2    | Accuracy | CV-AUC | $\Delta$ AUC | Tiempo |
|----------------------|--------|-------|--------|-------|----------|--------|--------------|--------|
| Random Forest        | 0,5543 | 0,617 | 0,304  | 0,285 | 74,2%    | 0,5952 | +0,020       | 39,0 s |
| XGBoost              | 0,5241 | 0,620 | 0,179  | 0,189 | 79,4%    | 0,6012 | -0,001       | 80,8 s |
| HistGradientBoosting | 0,4847 | 0,613 | 0,103  | 0,115 | 80,9%    | 0,5994 | +0,007       | 8,4 s  |
| Logistic Regression  | 0,4711 | 0,626 | 0,061  | 0,073 | 84,4%    | 0,5974 | -0,023       | 5,6 s  |
| Red Neuronal MLP     | 0,4509 | 0,594 | 0,003  | 0,004 | 84,8%    | 0,5830 | -0,008       | 12,9 s |

$Score = 0,35 \times Recall + 0,25 \times AUC + 0,20 \times CV-AUC + 0,10 \times (1 - |\Delta AUC|) + 0,10 \times (1 - Brier)$ . Umbral Stacking: 0,532 (Precisión  $\geq 25\%$ ).

### 3.4 Por qué el Stacking es el modelo final

#### Conclusión

El Stacking es el modelo seleccionado porque combina el mayor Recall (0,635), prácticamente cero sobreajuste ( $\Delta AUC = +0,001$ ) y la mayor estabilidad en validación cruzada. En el contexto clínico de este proyecto, donde no detectar a un paciente que reingresará tiene consecuencias graves, el Recall es la métrica determinante — y el Stacking lo dobla respecto al mejor modelo base individual.

Sin embargo, somos conscientes de que el Stacking no es universalmente óptimo. Su ventaja depende de condiciones que sí se cumplen aquí pero que no siempre estarán presentes:

- **Diversidad real entre modelos base:** El Stacking solo gana si cada modelo comete errores distintos. Aquí combinamos un modelo lineal (LR), dos variantes de boosting con filosofías distintas (HGB y XGBoost) y un ensemble de árboles independientes (RF). Si los cuatro fueran variantes del mismo algoritmo, el meta-modelo aprendería la media de predicciones casi idénticas sin ninguna ganancia.
- **Volumen de datos suficiente:** El out-of-fold requiere que cada fold sea representativo. Con menos de ~2.000 muestras los modelos base entrenados en el 80% restante son notablemente peores. Con 8.800 muestras de entrenamiento este riesgo es manejable.
- **Coste computacional:** En producción, cada predicción requiere ejecutar 4 modelos base más el meta-modelo en secuencia. En sistemas con millones de predicciones por segundo o restricciones de latencia estrictas, este coste se multiplica por 5 respecto a un modelo único. En este proyecto el volumen de predicciones es bajo y el tiempo total es de 2,6 s, por lo que no supone un problema.
- **Interpretabilidad:** En contextos con requisitos regulatorios (RGPD, auditorías hospitalarias, dispositivos médicos bajo supervisión de la FDA) es obligatorio explicar por qué el modelo asignó un riesgo concreto a un paciente. El Stacking dificulta esa trazabilidad. En entorno con esas restricciones, una Regresión Logística sería preferible, aunque su Recall fuera inferior.

En este proyecto, al tratarse de un entorno académico con datos suficientes, modelos base diversos, bajo volumen de predicciones y sin restricciones regulatorias, las condiciones se cumplen y el Stacking está justificado como elección final.