




Healthcare Medical Project

PRESENTADO POR
DAVID MOURENZA
ENRIQUE JIMENEZ
Gael DIAZ
PAULA DOMINGUEZ

DESCRIPCION DEL CASO DE USO


- DATASET SANITARIO CON **100.000 PACIENTES** Y MÁS DE **3 MILLONES DE REGISTROS CLÍNICOS**.
- OBJETIVO: DESARROLLAR MODELOS PREDICTIVOS QUE ESTIMEN EL RIESGO DE REINGRESO CLÍNICO EN 30 DÍAS.
- INFORMACIÓN DISTRIBUIDA EN 5 TABLAS:
 - PACIENTES
 - DIAGNÓSTICOS
 - MEDICACIÓN
 - RESULTADOS DE LABORATORIO
 - HOSPITALIZACIONES

ESQUEMA FUNCIONAL



AZURE SYNAPSE PROCESA Y TRANSFORMA LOS DATOS DE **AZURE** USANDO **PYSPARK** PARA ALIMENTAR EL **PORTAL MÉDICO "SISTEMA UCI"** DESARROLLADO EN **STREAMLIT** (BAJO UN ENTORNO IMPLEMENTADO CON **DOCKER**) Y GENERAR REPORTES ANALÍTICOS EN **POWER BI**.

RESOLUCION TÉCNICA: MODELADO



RESOLUCION TÉCNICA: INGESTA + CALIDAD + IA

INGESTA

CARGA DE 5 CSV . TOTAL: 3.577.489 REGISTROS. ESCRITURA EN PARQUET EN /BRONZE/.

APLICANDO **ESQUEMA TIPADO ESTRICTO** Y PERSISTENCIA DE **LOGS DE EJECUCIÓN** PARA GARANTIZAR LA TRAZABILIDAD Y LA INTEGRIDAD DESDE EL ORIGEN.

CALIDAD

AUDITORÍAS: CONTEO, TIPADO, NULOS, DUPLICADOS, INTEGRIDAD REFERENCIAL , RANGOS CLÍNICOS.

LIMPIEZA: °F → °C · FLAGS DX_* A BOOLEANOS · FECHAS A DATETYPE · STRINGS NORMALIZADOS · FILTRO TEMPORAL. ESCRITURA EN /SILVER/.

FEATURE ENGINEERING — 22 VARIABLES DERIVADAS

🕒 TEMPORALES (4)

admission_month	admission_weekday
admission_quarter	n_comorbidities

💰 UMBRALES (5)

high_charlson ≥3	high_creatinine
high_abnormal	high_meds
high_emergency	

🔑 INTERACCIONES (8)

ch_x_meds	crea_x_charlson
ch_x_emergency	ch_x_abnormal
abnormal_x_meds	delta_x_ch
meds_x_adh	ch_x_comorb

🇮🇹 SCORE+NOLINEAL (4)



clinical_risk_score	charlson_sq
creatinine_sq	risk_score_sq

PIPELINE DE DATOS Y FLUJO DE TRABAJO ETL

3 Capa Bronze: Agrupa los notebooks 00, 01 y 01b.
"Ingesta y Reglas de Calidad"

2 Capa Silver: Agrupa los notebooks 02, 03 y 03b.
"Limpieza, Estandarización y EDA"

1 Capa Gold: Agrupa el notebook 06 y el modelo predictivo.
"BI y Machine Learning"



Validación de Modelos y Comparativa de Métricas

Logistic Regression ✓

Pondera variables → Sigmoid → Probabilidad

Baseline · C=0.01 · L2 fuerte

AUC 0.626 · Recall 0.061

Random Forest ~

200 árboles en paralelo → Voto mayoritario

200 árboles · max_depth=4

AUC 0.617 · Recall 0.304

HistGradientBoosting ~

Árboles secuenciales que agrupan valores en bis para evaluar menos cortes

50× rápido · L2=10 · early stop

AUC 0.613 · Recall 0.103

Red Neuronal MLP ✗

Capas neuronales, transforman señal progresivamente

32→16 · ReLU · alpha=10

AUC 0.594 · Recall 0.003

XGBoost ~

Árboles secuenciales que tratan datos individualizados

L1+L2 · $\gamma=0.1$ · min_child=15

AUC 0.620 · Recall 0.179

Estrategia del Modelo Final

63.5%

Recall Máximo (F2: 0.431)

El Poder del "Stacking"

El meta-modelo Stacking combina las fortalezas únicas de la Regresión Logística, HistGradientBoosting, XGBoost y Random Forest. Al aprender de los errores individuales de cada algoritmo base, logra:

- Duplicar el Recall del siguiente mejor modelo individual.
- Maximizar el F2-score garantizando una Precisión $\geq 25\%$ (1 alerta real por cada 4 emitidas).
- Un nivel casi nulo de sobreajuste (ΔAUC de +0.001 entre entrenamiento y test).

POWERBI



Visión operativa y financiera

Perfil del Paciente y Constantes Vitales

Gráficos de Laboratorio

Web APP




Conclusiones

- **Eficiente:** Arquitectura robusta en Azure y modelo predictivo (Stacking) optimizado con un Recall del 63,5%.
- **Práctico:** Interfaz clínica intuitiva. Power BI para el hospital y Web App para pacientes y personal médico.
- **Asequible:** Gestión inteligente de recursos Cloud y uso de modelos de lenguaje (LLMs) integrados.
- **Rentable:** Optimización de recursos hospitalarios y prevención de reingresos que superan los 15.000\$ por paciente.



¿Preguntas?

Gracias por su atención en la revisión del Proyecto Médico.



NTT Data | Máster FP Dual en Inteligencia Artificial y Big Data